



UNIVERSITÉ JOSEPH KI-ZERBO
(UJKZ)

INSTITUT BURKINABÈ DES ARTS ET MÉTIERS
(IBAM)



Cours : Web Sémantique et Web de Données

MANUEL D'UTILISATION

Moteur de recherche sémantique pour le mooré

Recherche Web multilingue : mooré, français, anglais

Présenté par

SAVADOGO Adjaratou

KOMPAORE Malick

OUEDRAOGO Abdoul Razack

KABORE Olivier

Encadré par

Dr. GUINKO T. Ferdinand

Année universitaire 2025–2026

Sommaire

Liste des sigles et abréviations	5
1. Introduction	6
1.1 Présentation de l'application	6
1.2 Architecture technique	6
1.3 Contenu du dossier livré	6
2. Prérequis	8
3. Installation	8
3.1 Récupérer le projet	8
3.2 Environnement virtuel et dépendances	8
3.3 (Optionnel) Index sémantique	9
3.4 Vérifier l'installation	9
4. Lancement de l'application	9
5. Guide d'utilisation	11
5.1 L'écran de recherche	11
5.2 Onglet « Web » : chercher des pages	11
5.3 Onglet « Dictionnaire »	13
5.4 Onglet « Traduction FR → mooré »	15
5.5 Utilisation en ligne de commande	15
6. Résolution des problèmes	17
7. Limites connues	17
8. Conclusion	17
Annexe A : Arborescence et adresses	19
Annexe B : Conformité au cahier des charges	20

Liste des figures

5.1 Le panneau de recherche et ses trois onglets	11
5.2 Le pont de traduction affiché au-dessus des résultats	11
5.3 Pages Web trouvées pour la requête mooré « koom »	12
5.4 L'onglet Dictionnaire : filtres et sélecteur d'index	13
5.5 Une entrée et ses renvois	13
5.6 Le compteur rappelle le filtre de domaine actif	13
5.7 Avertissement lorsque l'index choisi ne convient pas	14
5.8 Ressources externes proposées pour un mot	14
5.9 Glose d'une phrase française	15
5.10 Tournures idiomatiques proposées	15

Liste des tableaux

1 Sigles et abréviations	5
1.1 Contenu du dossier livré	6
2.1 Prérequis matériels et logiciels	8
5.1 Les cinq index de recherche	14
6.1 Problèmes fréquents et solutions	17
A.1 Récapitulatif des adresses	19
B.1 Conformité aux exigences fonctionnelles	20

Liste des sigles et abréviations

Tableau 1 : Sigles et abréviations employés dans ce manuel.

Sigle	Signification
API	<i>Application Programming Interface</i> : interface de programmation
CORS	<i>Cross-Origin Resource Sharing</i> : règle du navigateur autorisant ou non un site à interroger un autre
FAISS	<i>Facebook AI Similarity Search</i> : bibliothèque de recherche de vecteurs proches
Flask	Micro-framework web Python utilisé pour l'API
JSON	<i>JavaScript Object Notation</i> : format d'échange de données
LSA	<i>Latent Semantic Analysis</i> : réduction de dimension appliquée au TF-IDF
MediaWiki	Moteur des sites Wikipédia et Wiktionnaire, doté d'une API publique
RRF	<i>Reciprocal Rank Fusion</i> : fusion de deux classements par les rangs
SVD	<i>Singular Value Decomposition</i> : décomposition employée par la LSA
TF-IDF	<i>Term Frequency – Inverse Document Frequency</i> : pondération des mots d'un document
UTF-8	Encodage de caractères, nécessaire aux diacritiques du mooré

1. Introduction

1.1 Présentation de l'application

Gvls-n bao est un moteur de recherche Web multilingue conçu pour le mooré. L'utilisateur formule une requête en **mooré**, en **français** ou en **anglais**, et l'application lui rend des pages Web accompagnées de leur titre, d'un extrait et d'un lien direct.

Le cœur du dispositif est un dictionnaire vectoriel construit sur le corpus *Webonary Moore*, qui compte 10 566 entrées. Ce dictionnaire ne sert pas seulement à consulter des mots : il fait office de **pont de traduction**.

Ce point mérite une explication, car il commande tout le fonctionnement de l'application. Un moteur de recherche ordinaire interrogé avec le mot mooré `koom` ne rend rien d'utile : ce mot ne figure pas dans les pages qu'il a indexées. Nous traduisons donc la requête avant de l'envoyer. `koom` devient « eau », et c'est ce terme qui part vers les sources francophones, pendant que le mot d'origine part vers les sources rédigées en mooré. Une requête française suit le chemin inverse. C'est ce passage par le dictionnaire qui rend le moteur réellement multilingue au lieu de le laisser buter sur la langue de départ.

Trois usages, trois onglets. **Web** cherche des pages sur Internet ; **Dictionnaire** explore le corpus mooré (définitions, synonymes, domaines) ; **Traduction** glose une phrase française entière en mooré. L'onglet Web est actif au démarrage, les deux autres restent accessibles à tout moment et fonctionnent sans connexion.

1.2 Architecture technique

- **Corpus** : `data/corpus_moore_webonary.csv`, 10 566 entrées mooré avec définitions française et anglaise, catégorie grammaticale, prononciation, domaine, synonymes, antonymes, variantes et pluriel.
- **Index vectoriels** : cinq index complémentaires (voir § 5.3), fondés sur TF-IDF/LSA, sur des n-grammes de caractères et, en option, sur des embeddings multilingues pré-entraînés. La recherche des voisins est assurée par **FAISS**.
- **Sources Web** : les API publiques de **Wikipédia en mooré**, **Wikipédia en français** et du **Wiktionnaire**. Aucune clé d'API n'est nécessaire.
- **Back-end** : une application **Flask** (Python) qui expose des API JSON et sert l'interface.
- **Front-end** : une page HTML/CSS/JavaScript sans framework, incluant un clavier virtuel pour les caractères propres au mooré.

1.3 Contenu du dossier livré

Tableau 1.1 : Fichiers et dossiers du projet.

Élément	Rôle
<code>api.py</code>	Point d'entrée : API Flask et service de l'interface
<code>search.py</code>	Recherche dans le corpus ; les cinq index et leur routage
<code>recherche_web.py</code>	Recherche sur le Web et pont de traduction
<code>translate.py</code>	Glossage d'une phrase française en mooré
<code>liens.py</code>	Ressources externes proposées pour un mot

<code>embeddings.py</code>	Modèle d'embeddings pré-entraîné (optionnel)
<code>build_index.py</code>	Construit l'index TF-IDF/LSA à partir du corpus
<code>build_st_index.py</code>	Construit l'index sémantique (optionnel)
<code>benchmark.py</code>	Compare les index sur trois tâches, chiffres à l'appui
<code>test_moteur.py</code>	66 tests de non-régression
<code>moteur_recherche_moore_live.html</code>	Interface web
<code>data/</code>	Le corpus source au format CSV
<code>vectors.index, vectorizers.pkl, corpus_meta.pkl</code>	Base vectorielle déjà construite, fournie prête à l'emploi
<code>requirements.txt</code>	Dépendances Python
<code>README.md</code>	Documentation technique détaillée

2. Prérequis

L'application est multiplateforme : elle s'installe de la même manière sous Windows, Linux et macOS.

Tableau 2.1 : Prérequis matériels et logiciels.

Logiciel	Version	Utilité
Python	3.9 ou plus (testé sur 3.11)	Exécuter l'application
pip	fourni avec Python	Installer les dépendances
Navigateur web	récent (Chrome, Edge, Firefox)	Consulter l'interface
Connexion Internet	requis pour l'onglet Web	Interroger Wikipédia et le Wiktionnaire
Espace disque	≈ 100 Mo (1,2 Go avec l'index sémantique)	Corpus et index

Vérifier la version de Python dans un terminal :

```
python --version
```

Si `python` n'est pas reconnu sous Windows, réinstaller Python en cochant l'option « **Add Python to PATH** », ou utiliser `py` à la place.

Les onglets Dictionnaire et Traduction fonctionnent hors ligne. Seul l'onglet Web a besoin d'une connexion, puisqu'il interroge des sites externes.

3. Installation

3.1 Récupérer le projet

```
git clone https://github.com/malickabdoul/codebydarknet.git
cd codebydarknet
git checkout feature/base-vectorielle
```

Vérifier la présence de `api.py`, `requirements.txt`, du dossier `data/` et des trois fichiers de la base vectorielle (`vectors.index`, `vectorizers.pkl`, `corpus_meta.pkl`).

La base vectorielle est fournie construite. Il n'est pas nécessaire de la reconstruire pour utiliser l'application. Ne relancer `build_index.py` qu'après avoir modifié le corpus.

3.2 Environnement virtuel et dépendances

L'environnement virtuel évite les conflits avec les autres projets Python.

Windows


```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
```

Linux / macOS

```
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
```

Le préfixe `(.venv)` doit apparaître au début de la ligne de commande. Sont installés : `pandas`, `numpy`, `scipy`, `scikit-learn`, `faiss-cpu`, `flask` et `flask-cors`.

3.3 (Optionnel) Index sémantique

Un index supplémentaire, fondé sur un modèle d'embeddings multilingue, améliore nettement les requêtes en français et en anglais. Il est **facultatif** : sans lui, l'application se rabat automatiquement sur les index lexicaux et rien ne cesse de fonctionner.

```
pip install sentence-transformers
python build_st_index.py
```

Cette étape télécharge environ 1 Go (la bibliothèque `torch` puis le modèle) et l'encodage du corpus prend deux à trois minutes. Elle ne se fait qu'une seule fois.

3.4 Vérifier l'installation

```
python test_moteur.py
```

La suite compte **66 tests** et s'exécute en moins de deux minutes. Le message final doit être `OK`. Les tests qui exigent l'index sémantique se sautent d'eux-mêmes s'il n'a pas été construit ; ceux qui interrogent le Web se sautent en l'absence de connexion.

4. Lancement de l'application

Dans le terminal, environnement virtuel activé :

```
python api.py
```

Le démarrage affiche :

```
Chargement de la base vectorielle...
-> 10566 entrées, 52 domaines
-> interface : http://127.0.0.1:5000/
```

Laisser ce terminal ouvert. Ouvrir ensuite un navigateur à l'adresse **`http://127.0.0.1:5000/`**. L'interface s'affiche.

Pour arrêter l'application, appuyer sur **Ctrl+C** dans son terminal.

Deux façons d'ouvrir l'interface. La méthode ci-dessus est recommandée : tout est servi par la même adresse. Il reste possible de double-cliquer le fichier `moteur_recherche_moore_live.html` ; la page détecte alors qu'elle est ouverte depuis le disque et interroge `http://127.0.0.1:5000`, que l'API autorise explicitement.

5. Guide d'utilisation

5.1 L'écran de recherche

L'écran se compose d'un panneau unique : les trois onglets, la barre de recherche, le clavier des caractères mooré et, selon l'onglet, les filtres par domaine.




Figure 5.1 : Le panneau de recherche. Les trois onglets en haut à gauche commutent entre la recherche Web, le dictionnaire et la traduction. Le clavier virtuel insère les dix caractères du mooré absents des claviers standards.

Le clavier mooré

Les caractères **ã ë ĩ õ ũ ε ɪ ʊ ŋ ɲ** ne figurent pas sur un clavier ordinaire. Cliquer sur une touche l'insère à la position du curseur et relance la recherche. Le bouton **Effacer** vide le champ.

Ces caractères ne sont pas obligatoires. La recherche tolère leur absence : taper **bag-teoko** retrouve **băg-tēoko**.

5.2 Onglet « Web » : chercher des pages

C'est l'onglet actif au démarrage. Saisir un mot en mooré, en français ou en anglais : l'application détecte la langue, traduit la requête à l'aide du corpus, interroge les sources Web, puis affiche les pages trouvées.

Un bandeau explique le **pont de traduction** employé, afin que l'utilisateur sache toujours sur quel terme la recherche a réellement porté.




Figure 5.2 : Le pont de traduction. Le mot mooré **koom** a été traduit en « **eau** » par le corpus ; c'est ce terme qui a été soumis aux sources francophones, tandis que **koom** était soumis au Wikipédia en mooré.

Chaque résultat comporte trois éléments :

- le **titre** de la page, cliquable, qui ouvre la page dans un nouvel onglet ;
- un **extrait** situant le contenu ;

- la **source** et le terme sur lequel la recherche a porté.

Les pages en mooré sont signalées par un liseré rouge et réparties parmi les résultats. Cette précaution est délibérée : le modèle sémantique ne connaît pas le mooré et, laissé libre, reléguait systématiquement ces pages en fin de liste, un contresens dans un moteur destiné à des locuteurs du mooré.

Pont de traduction : « koom » traduit en « eau » par le corpus.
Sources interrogées : Wikipédia en mooré, Wikipédia, Wiktionnaire

Wikipédia en mooré
Tsuchizaki Shinmeisha wënd-doogã yvǝmdã kibs la koom-koglgã kibsã kibs
zĩnd Tsuchizakiminato, sēn yaa Akita tēnga sēn be ko-bāoogo. [1] B sēn dɪkd koom-koglgã n na n tɪ
moonē wā yaa koglg 20 bi. A tūud-n-ta-taasā yaa a Shinmeisha
recherché : « koom »

Wikipédia
Cours d'eau
Pour les articles homonymes, voir Cours. Un cours d'eau Écouter est un écoulement terrestre d'eau liquide
entre une source et une embouchure ou une confluence
recherché : « eau » · proximité 0.69

Wikipédia
Eau saumâtre
tes articles homonymes, voir Eau salée. Une eau saumâtre est une eau dont la teneur en sel est inférieure
à celle de l'eau de mer. La concentration totale
recherché : « eau » · proximité 0.66

Wikipédia en mooré
Noria
pāng koomā wēngē, b sēn tūnugd ne n zēkd koom n kēesd koom-koglg pugē, sēn na yɪl n kō koom-
koglg wall koom tɪ ta tēn-bed la tēn-bōonegē. No-rɪk gom-bil
recherché : « koom »

Wikipédia
Eau
précise : eau minérale, eau de Seltz, eau de source, eau de mer, eau douce, eau potable, eau de pluie, eau
du robinet, eau de table, eau gazeuse, eau plate
recherché : « eau » · proximité 0.65

Wikipédia
Eau potable
Une eau est dite potable (du latin potabilis, qui signifie « qui peut être bu ») lorsqu'elle présente certaines
caractéristiques — concentration en chlorures
recherché : « eau » · proximité 0.65

Wikipédia en mooré
Ko-yūdga
ko-yūdga Koom yaa būmb sēn pa tar yū-noog sēn tar bāngre. A yaa būmb sēn yaa vēenega, sēn ka tar
yūugu, sēn ka tar yūugu, la sēn ka tar vēere, la a yaa
recherché : « koom »

Wiktionnaire
eau
aussi : EAU, ÉAU, éau, -eau (Xle siècle) Du moyen français eaue, eau, de l'ancien français eaue, ewe, du
latin aqua, du proto-italique *ak*ā (« eau »), de
recherché : « eau » · proximité 0.65

Wiktionnaire
eau courante
purifier l'eau courante. — (site www.takesumi.fr) eau stagnante eau croupie eau de process eaux blanches
eaux noires eaux de lavage eaux vannes eau du robinet
recherché : « eau » · proximité 0.62

Wikipédia en mooré
Haenyeo
pagb sēn kēed koom-koglgã pugē, Koore-Dĩng soolmā Jeju soolmā wā. B sēn paamd b yōor yōor yaa b
sēn paamd koom-koglg buud toor-toore, koom-kogend la bōn-buud
recherché : « koom »

Figure 5.3 : Pages trouvées pour la requête mooré **koom**. Les résultats mêlent le Wikipédia en mooré (liseré rouge), le Wikipédia en français et le Wiktionnaire. L'indication « proximité » est le score de reclassement sémantique.

5.3 Onglet « Dictionnaire »

Cet onglet interroge le corpus mooré, sans connexion Internet. Il affiche les entrées les plus proches du terme saisi, avec leurs définitions française et anglaise, leur catégorie grammaticale, leur prononciation et leur domaine.




Figure 5.4 : L'onglet Dictionnaire ajoute deux commandes : le sélecteur **Index** en haut à droite, et les **puces de domaine** qui restreignent la recherche à un champ sémantique (Water, Bird, Disease...). Ces 52 domaines sont déduits du corpus.

Les renvois

Chaque entrée affiche, lorsqu'ils existent, ses **synonymes**, son **contraire**, ses **variantes**, son **pluriel** et le nombre d'**autres sens** du même mot. Tous ces renvois sont cliquables et relancent la recherche.



Figure 5.5 : L'entrée **ba** (« père ») et ses renvois : le synonyme *saamba*, le contraire *ma* (« mère »), la variante *baaba*, le pluriel *ba-râmba* et cinq autres sens du mot.

Filtrer par domaine

Cliquer sur une puce restreint les résultats à ce domaine ; recliquer la désactive. Le filtrage est effectué côté serveur, avant la sélection des meilleurs résultats, sans quoi un filtre renverrait souvent une liste vide.

20 résultats pour « eau » dans « Water » (triés par proximité de sens)

Figure 5.6 : Le compteur rappelle le filtre actif.

Choisir l'index

Le sélecteur **Index** permet de choisir la méthode de recherche. Le mode **Auto**, actif par défaut, choisit lui-même selon la langue de la requête ; les autres valeurs servent surtout à comparer les méthodes.

Tableau 5.1 : Les cinq index et leur usage.

Index	Ce qu'il fait
Auto	Choisit selon la langue détectée. Recommandé.
Mots mooré	N-grammes de caractères sur les entrées ; retrouve un mot mooré même mal orthographié
TF-IDF seul	L'index d'origine : entrées et définitions mélangées
Sémantique seul	Embeddings pré-entraînés ; comprend le sens en français et en anglais
Hybride (RRF)	Fusion des deux précédents par les rangs

Forcer un index inadapté à la requête produit du bruit. L'application le détecte et le signale, avec un bouton de retour au mode automatique.



Figure 5.7 : Avertissement affiché lorsqu'on soumet un mot mooré à l'index sémantique. Le modèle employé couvre une cinquantaine de langues parmi lesquelles le mooré ne figure pas.

Consulter le mot ailleurs

Sous les résultats, la rubrique « **Sur le web** » propose des ressources externes pour le premier mot trouvé. Ces pages ne font pas partie du corpus, et l'interface le précise.




Figure 5.8 : Ressources externes. Deux sources portent un avertissement : le Wiktionnaire annonce parfois un code d'erreur alors que la page s'affiche, et Webonary, la source du corpus, est protégé par un dispositif anti-robot.

5.4 Onglet « Traduction FR → mooré »

Cet onglet traite une **phrase entière**. La phrase est découpée, et chaque segment reçoit son équivalent mooré. Les expressions figées connues du corpus sont reconnues d'un seul bloc plutôt que mot à mot.




Figure 5.9 : Glose de « je veux boire de l'eau ». Chaque segment montre son équivalent et ses variantes. *veux* a été ramené à *vouloir* ; *de* et *l'* sont marqués « non traduit », le mooré n'ayant ni articles ni cette préposition.

Ce résultat est une glose, pas une traduction. C'est le meilleur équivalent mooré de chaque segment, dans l'ordre du français. Le mooré a son propre ordre des mots, ses postpositions et ses marques d'aspect, qu'un dictionnaire ne permet pas de reconstruire. La glose est un support pour un locuteur, pas une phrase à publier telle quelle, et l'interface l'indique sous chaque résultat.

Tournures idiomatiques

Une glose littérale ne peut pas deviner qu'une expression se dit autrement. L'application interroge donc aussi la base vectorielle sur la phrase entière et propose les tournures figées qui s'en rapprochent par le sens.




Figure 5.10 : Pour « tu vas bien », la glose donne *fkibe neere* (mot à mot), mais la base vectorielle propose **laafi bala**, la tournure réellement employée. Aucun mot ne coïncide : seule une comparaison de sens pouvait la trouver.

Ces suggestions sont affichées avec leur score de proximité et présentées comme à **valider par un locuteur**. Elles sont fiables sur les formules courantes, bruitées sur les phrases descriptives.

5.5 Utilisation en ligne de commande

Toutes les fonctions sont accessibles sans interface :

```
# chercher des pages sur le Web
python recherche_web.py "koom"
```

```
# consulter le dictionnaire
python search.py "eau"
python search.py "eau" --domaine Water
python search.py "koom" --backend entrees

# gloser une phrase
python translate.py "je veux boire de l'eau"

# comparer les index, chiffres à l'appui
python benchmark.py
```


6. Résolution des problèmes

Tableau 6.1 : Problèmes fréquents et solutions.

Symptôme	Cause probable	Solution
python n'est pas reconnu	Python absent ou hors du PATH	Réinstaller Python en cochant Add Python to PATH , ou utiliser <code>py</code>
<code>ModuleNotFoundError</code> : <code>faiss</code>	Dépendances non installées	Activer l'environnement virtuel puis <code>pip install -r requirements.txt</code>
« Impossible de joindre l'API »	<code>api.py</code> n'est pas lancé	Relancer <code>python api.py</code> et laisser le terminal ouvert
« Port 5000 déjà utilisé »	Une autre instance tourne déjà	Fermer l'ancien terminal, ou changer le port dans <code>api.py</code>
L'onglet Web ne rend rien	Pas de connexion Internet	Vérifier la connexion. Les onglets Dictionnaire et Traduction restent utilisables hors ligne
Le sélecteur d'index est absent	L'index sémantique n'est pas construit	Comportement normal : un seul index est disponible. Voir § 3.3
Résultats manifestement hors sujet	Un index inadapté a été forcé	Repasser sur Auto ; l'application affiche un avertissement dans ce cas
Une définition finit par [...]]	Le texte est coupé dans le corpus source	Rien à faire : le marqueur signale une donnée incomplète, pas une erreur d'affichage
Recherche sans résultat	Mot trop rare ou absent du corpus	Essayer un synonyme, ou passer par l'onglet Web

7. Limites connues

Cette section recense ce que l'application ne fait pas. Nous préférons l'écrire ici plutôt que de laisser un utilisateur le découvrir en se fiant à un résultat qu'il aurait cru plus solide qu'il ne l'est.

- **Les sources Web sont au nombre de trois** : Wikipédia en mooré, Wikipédia en français et le Wiktionnaire. Il ne s'agit pas d'une exploration de tout le Web. Ces trois sources ont été retenues parce qu'elles offrent une API publique, sans clé ni quota. L'architecture prévoit l'ajout d'un moteur généraliste, qui exigerait une clé d'API.
- **Le Wikipédia en mooré est petit** : 1 326 articles. Certaines requêtes n'y trouveront rien, et seuls les résultats francophones s'afficheront.
- **La traduction est une glose**, pas une phrase mooré grammaticale (voir § 5.4).
- **La recherche vocale n'est pas implémentée**. Le cahier des charges la classe en priorité basse et la range parmi les évolutions futures.
- **Le corpus comporte des défauts** hérités de sa source : 74 définitions coupées, une ligne aux colonnes décalées, quelques doublons. Ceux qui pouvaient l'être sont corrigés à l'affichage ; les autres sont documentés dans le `README.md`.
- **L'interface est en français**. Le public visé comprend des locuteurs du mooré ne maîtrisant pas nécessairement le français écrit : une traduction de l'interface reste à faire.

8. Conclusion

L'application est autonome. Une fois les dépendances installées, la commande `python api.py` suffit à la démarrer, et l'interface est immédiatement disponible sur **<http://127.0.0.1:5000/>**. Aucun serveur de données externe n'est à configurer : la base vectorielle est fournie construite dans le dépôt, et les index lexicaux fonctionnent sans aucune installation supplémentaire.

Le moteur répond à une requête formulée en mooré, en français ou en anglais, et rend des pages Web avec leur titre, un extrait et un lien. Le corpus Webonary sert de pont entre les langues, et un reclassement par proximité de sens améliore la pertinence des pages proposées. Deux onglets complémentaires donnent accès au dictionnaire lui-même et au glossage de phrases.

Nous avons cherché, dans ce manuel, à ne pas présenter l'application comme plus capable qu'elle ne l'est. Les résultats du mode Traduction sont des gloses et non des phrases mooré ; les suggestions de tournures idiomatiques demandent d'être validées par un locuteur ; les sources Web se limitent à trois encyclopédies. Ces réserves figurent dans la section 7 plutôt qu'en note de bas de page, parce qu'un utilisateur qui les ignore se méprendra sur ce qu'il lit à l'écran.

Les évolutions envisagées sont l'ajout d'un moteur de recherche généraliste comme quatrième source, la reconnaissance vocale, la traduction de l'interface en mooré, et l'extension à d'autres langues nationales du Burkina Faso.

Annexe A : Arborescence et adresses

```
codebydarknet/
|-- api.py                # API Flask, sert aussi l'interface
|-- search.py            # recherche dans le corpus, 5 index
|-- recherche_web.py     # recherche Web + pont de traduction
|-- translate.py         # glossage d'une phrase
|-- liens.py             # ressources externes
|-- embeddings.py        # modele pre-entraîne (optionnel)
|-- build_index.py       # construit l'index TF-IDF/LSA
|-- build_st_index.py    # construit l'index sémantique
|-- benchmark.py         # comparaison chiffrée des index
|-- test_moteur.py       # 66 tests de non-régression
|-- moteur_recherche_moore_live.html # interface web
|-- requirements.txt
|-- README.md
|-- data/
|   |-- corpus_moore_webonary.csv # 10 566 entrées
|-- vectors.index        # index FAISS (fourni)
|-- vectorizers.pkl      # vectoriseurs entraînés (fourni)
|-- corpus_meta.pkl      # métadonnées alignées (fourni)
'-- docs/
    |-- manuel_utilisation.pdf    # le présent manuel
    |-- captures/                # captures d'écran
```

Tableau A.1 : Récapitulatif des adresses.

Élément	Adresse
Interface	http://127.0.0.1:5000/
Recherche Web	/api/web?q=koom&k=8
Dictionnaire	/api/search?q=eau&k=10[&domaine=Water][&backend=auto]
Traduction	/api/translate?q=je veux boire de l'eau
Ressources externes	/api/liens?q=koom[&fr=eau]
Liste des domaines	/api/domaines
État du service	/api/health
Dépôt du projet	github.com/malickabdoul/codebydarknet
Branche de travail	feature/base-vectorielle

Annexe B : Conformité au cahier des charges

Ce tableau reprend les quinze exigences fonctionnelles du cahier des charges et indique l'état de chacune.

Tableau B.1 : Conformité aux exigences fonctionnelles.

Réf.	Exigence	Priorité	État	Où
EF01	Saisir un mot ou une expression	Haute	Satisfaite	§ 5.2, 5.4
EF02	Requêtes en mooré	Haute	Satisfaite	§ 5.2, 5.3
EF03	Requêtes en français	Haute	Satisfaite	§ 5.2, 5.3
EF04	Requêtes en anglais	Haute	Satisfaite	§ 5.2, 5.3
EF05	Caractères spécifiques du mooré	Haute	Satisfaite	§ 5.1
EF06	Traiter la requête de l'utilisateur	Haute	Satisfaite	§ 5.2
EF07	Effectuer une recherche sur le Web	Haute	Satisfaite	§ 5.2
EF08	Récupérer les résultats correspondants	Haute	Satisfaite	§ 5.2
EF09	Afficher les résultats sous forme de liste	Haute	Satisfaite	Figure 5.3
EF10	Afficher le titre et l'extrait de chaque résultat	Haute	Satisfaite	Figure 5.3
EF11	Fournir un lien vers la page Web	Haute	Satisfaite	§ 5.2
EF12	Consulter directement les pages correspondantes	Haute	Satisfaite	§ 5.2
EF13	Améliorer la pertinence par une approche sémantique	Moyenne	Satisfaite	§ 5.2, 5.3
EF14	Recherche vocale	Basse	Non traitée	§ 7
EF15	Prise en charge de nouvelles langues	Basse	Non traitée	§ 7

Les douze exigences de priorité haute et l'exigence de priorité moyenne sont satisfaites. Les deux exigences restantes sont de priorité basse et rangées par le cahier des charges lui-même parmi les *perspectives d'évolution*.

Exigences non fonctionnelles

- **Ergonomie et accessibilité** : interface à panneau unique, barre de recherche identifiable, résultats lisibles, clavier virtuel pour les caractères absents du clavier. Réserve : l'interface n'existe qu'en français (§ 7).
- **Performance** : la recherche dans le dictionnaire prend de 20 à 500 ms selon l'index. La recherche Web dépend des sources externes, interrogées en parallèle, et les réponses sont mises en cache.
- **Qualité des données** : les défauts du corpus source ont été recensés et, lorsque c'était possible, corrigés à l'affichage. Le reclassement sémantique améliore la pertinence des pages proposées.
- **Évolutivité** : les sources Web et les index de recherche sont enfichables : ajouter un moteur généraliste ou une nouvelle langue revient à déclarer une entrée supplémentaire.